Dokumentace jazyka Ilang

Obsah

1. Gramatika ..... 2.
2. Sémantika ..... 6.
   2.1. Typy ..... 6.
   2.2. Rozsah platnosti ..... 6.
   2.3. Hodnoty a výrazy ..... 6.
   2.4. Správa paměti ..... 6.
   2.5. Předávání argumentů ..... 6.
   2.6. Precedence operátorů ..... 7.
   2.7. Omezení ..... 7.
3. Psaní programů ..... 8.
   3.1. Hello World ..... 8.
   3.2. Práce s různými typy ..... 8.
   3.3. Deklarace funkcí ..... 8.
   3.4. Externí funkce ..... 8.
   3.5. Vstup a výstup ..... 9.
   3.6. Práce s poli ..... 9.
   3.7. Neměnná globální hodnota ..... 9.
   3.8. Rekurze ..... 10.
   3.9. Cyklus ..... 10.
   3.10. Odkazy ..... 10.
4. Překladač ..... 11.
   4.1. Architektura ..... 11.
   4.2. Volací konvence ..... 11.
   4.3. Použití ..... 11.
   4.4. Rozbor konkrétního programu ..... 12.

1. Gramatika

Níže je vypsaná formální gramatika jazyka ve formě ekvivalentí s rozšířenou Backus-Naurovou formou.

```
program →
  { ( external_declaration | function_declaration | comment ) }
```

```
comment →
  `#` ? any characters ? `\n`
```

```
external_declaration →
  `extrn` type identifier `(`
    ( [ argument { `,` argument } [ `,` `…` ] ] | `…` )
  `)`
```

```
function_declaration →
  type identifier `(`
    [ argument { `,` argument } ]
  `)` block_expression
```

```
argument →
  type identifier
```

```
block_expression →
  `{` { expression `;` } [ expression ] `}`
```

```
expression →
  ( return | bind | assignment | value )
```

```
value →
  ( primary | binary | unary )
```

```
return →
  `return` value
```

```
bind →
  `let` identifier `:` type `=` value
```

```
assignment →
  ( identifier | index | deref ) `=` value
```

```
deref →
  `@` identifier
```

```
binary →
  primary binary_operator value
```

```
unary →
  unary_operator primary
```

```
index →
  identifier `[` value `]`
```

```
primary →
  ( literal | identifier | call | separated | block | condition | index |
deref | loop | make | release )
```

```
make →
  `make` `(` basic_type `,` value `)`
```

```
release →
  `release` `(` identifier `)`
```

```
loop →
  `for` value block_expression
```

```
literal →
  ( basic_literal | array_literal )
```

```
basic_literal →
  ( int_literal | float_literal | string_literal | bool_literal )
```

```
array_literal →
  `[` value { `,` value } `]`
```

```
separated →
  `(` value `)`
```

```
condition →
  `if` value value [ `else` value ]
```

```
identifier →
  letter { ( letter | digit | `_` ) }
```

```
int_literal →
  digit { digit }
```

```
float_literal →
  digit { digit } `.` digit { digit }
```

```
string_literal →
  `"` ? any characters ? `"`
```

```
bool_literal →
  ( `true` | `false` )
```

```
type →
  ( basic_type | array_type | slice_type | pointer_type )
```

```
basic_type →
  ( `int` | `bool` | `float` | `string` | `unit` )
```

```
pointer_type →
  `^` basic_type
```

```
binary_operator →
  ( `+` | `-` | `*` | `/` | `==` | `!=` | `<` | `>` | `<=` | `>=` | `<<` |
`>>` | `||` )
```

```
unary_operator →
  ( `-` | `!` | `^` | `@` )
```

```
letter →
  ( ? a … z ? | ? A … Z ? )
```

```
letter →
  ? 0 … 9 ?
```

2. Sémantika

2.1. Typy

Jazyk je staticky typovaný. Každý výraz má typ určený při překladu.

Základní typy jsou:
- **int** – 64bitové celé číslo se znaménkem
- **float** – 64bitové desetinné číslo, ekvivalent **double** v C
- **bool** – pravdivostní hodnota **true**(1) nebo **false**(0)
- **string** – odkaz na řetězec znaků zakončený nulou
- **unit** – typ bez velikosti, používán pro výrazy bez návratové hodnoty

Složené typy jsou:
- **[N]T** – pole **N** prvků typu **T** alokované na zásobníku kde **N** je přirozené kladné číslo známé při překladu
- **[R]T** – odkaz na pole **R** prvků typu **T** alokované na zásobníku nebo haldě
- **[]T** – odkaz na pole prvků typu **T** alokované na zásobníku nebo haldě
- **^T** – odkaz na hodnotu základního typu **T**

2.2. Rozsah platnosti

Jazyk má pro proměnné jediný rozsah platnosti, a to v těle funkce. Všechny proměnné alokované pomocí **let** jsou přístupné od místa deklarace do konce těla funkce. Externí funkce deklarované pomocí **extrn** jsou dostupné v těle každé funkce nezávisle na pořadí deklarace. Normální funkce jsou dostupné ve vlastním těle(pro podporu rekurze) a v těle všech následujících funkcí.

2.3. Hodnoty a výrazy

Každý výraz vrací hodnotu. Bloky **{ … }** vrací hodnotu posledního výrazu v těle, pokud za ním není středník. V případě, že poslední výraz za sebou středník má, vrací **0**. Podmínka **if** vrací hodnotu větve, která byla vyhodnocena. Cyklus **for** vrací poslední hodnotu těla, nebo **0** pokud tělo neproběhlo ani jednou.

2.4. Správa paměti

Pole(arrays) jsou alokována na zásobníku a jejich velikost musí být známa při překladu. Dynamická pole(slices) jsou buďto odkazy na pole na zásobníku(tak jsou pole předávána do funkcí) nebo jsou alokována na haldě pomocí **make(T, N)**, kde **T** je základní typ a **N** je počet prvků, který nemusí být při překladu známý. Vestavěná funkce **make** je abstrakcí nad funkcí z libc **malloc**. Správa paměti je plně na uživateli, a tak musí alokovanou paměť dealokovat pomocí vestavěné funkce **relase(S)** kde **S** je identifikátor s typem **slice**. Vestavěná funkce **release** je abstrakcí nad funckcí z libc **free**.

2.5. Předávání argumentů

Argumenty jsou předávány hodnotou. Pole a odkazy na pole jsou předávány jako dvojice (**odkaz délka**). Úpravy prvků pole uvnitř funkce se tedy projeví i mimo ni, přiřazení pole ale nikoliv. To jenom upraví hodnotu odkazu a délky v lokální proměnné. Výjimka je pro argumenty s typem pole, kde známe délku při překladu. V tom případě dojde při přiřazení k hodnotě se stejným typem k překopírování prvků.

2.6. Precedence operátorů

Precedence operátorů není přímo definována gramatikou, ale následující tabulkou:

1	||
2	&&
3	==, ≠
4	<, >, ≤, ≥
5	+, -
6	*, /
7	≪, ≫

2.7. Omezení

Logické operátory nepodporují zkrácené vyhodnocení, vždy se vyhodnotí celý výraz. Indexování je povoleno jenom pro hodnoty typu **slice** nebo **array**, ne pro hodnoty typu **string**. Koerce typů je podporována jen pro implicitní převod hodnoty typu **array** na odkaz typu **slice**.

3. Psaní programů

3.1. Hello World

Jednoduchý program vypisující text na standardní výstup:

```
extrn unit printf(string format, ...)

int main() {
  printf("Hello, world!");
  0
}
```

3.2. Práce s různými typy

```
let x: int = 42;
let pi: float = 3.14;
let b: bool = false;
let s: string = "text";
```

3.3. Deklarace funkcí

Jednoduchá funkce vracející součet dvou argumentů:

```
extrn unit printf(string format, ...)

int add2(int a, int b) {
  a+b
}

int main() {
  printf("Hello, world!");
  0
}
```

3.4. Externí funkce

Ukázka použití funkcí z **<math.h>**, při překladu pomocí **gcc** potom nutno poskytnout linker flag **-lm**

```
extrn unit srand(int seed)
extrn int time(int loc)
extrn int rand()

srand(time(0));
let random_number: int = rand();
```

3.5. Vstup a výstup

Pro vstup a výstup se používají funkce ze standardní knihovny C:

```
extrn unit printf(string fmt, ...)
extrn int scanf(string fmt, ...)
extrn int putchar(int c)
extrn int getchar()
```

3.6. Práce s poli

Statické pole fixní velikosti:

```
let arr: [8]int = [1, 2, 3, 4, 5, 6, 7, 8];
arr[3] = 13;
let x: int = arr[3];  # x = 13
```

Dynamické pole alokované na haldě:

```
let n: int = 100;
let arr: [arr_len]int = make(int, n);
arr[0] = 42;
release(arr);
```

Předání pole do funkce a přiřazení délky lokální proměnné:

```
extrn unit printf(string format, ...)

unit print_int_slice_backwards([slice_len]int slice) {
  for slice_len > 0 {
    slice_len = slice_len - 1;
    printf("slice[%d] = %d\n", slice_len, slice[slice_len]);
  }
}

unit main() {
  let n: int = 10;
  let arr: []int = make(int, n);
  print_int_slice_backwards(arr);
  release(arr);
}
```

3.7. Neměnná globální hodnota

Použití funkce jako globální konstanty

```
int max_buffer_size() { 1024 }

unit main() {
  let buffer: []int = make(int, max_buffer_size());
  release(buffer);
}
```

3.8. Rekurze

Využití rekurze pro výpočet faktoriálu:

```
int factorial(int n) {
    if n <= 1 {
        1
    } else {
        n * factorial(n - 1)
    }
}
```

3.9. Cyklus

Využití návratové hodnody cyklu **for** pro iterativní výpočet faktoriálu:

```
let a: int = {
               let n: int = 5;
               let res: int = n;
               for n > 1 {
                 n = n-1;
                 res = res * n
               }
             };
```

3.10. Odkazy

Adresa proměnné se získá operátorem **^**, dereference operátorem **@**:

```
int x: int = 42;
let p: ^int = ^x;
@p = 100;  # x = 100
```

Přečtení čísla z standardního vstupu:

```
extrn int scanf(string format, ...)

int x: int = 0;
scanf("%d", ^x);
```

4. Překladač

4.1. Architektura

Překladač překládá zdrojový kód do GNU assembly pro architekturu x86_64. Skládá se z těchto částí:

- **Lexická analýza** – rozčlenění zdrojového kódu na tokeny
- **Syntaktická analýza** – sestavení abstraktního syntaktickýho stromu (AST) z tokenů
- **Vyhodnocení jmen** – projde strom a propojí identifikátory
- **Vyhodnocení typů** – projde strom a propaguje nahoru typy výrazů
- **Ověření typů** – ověření, jestli typy ve výrazech odpovídají očekávaným
- **Generátor kódu** – projde strom a vygeneruje odpovídající assembly

Výsledný assembly kód je přeložen pomocí GCC do spustitelného souboru.

4.2. Volací konvence

Překladač generuje kód dodržující konvenci System V AMD64 ABI, která se používá na Linuxových systémech. Celočíselné argumenty jsou předávány nejprve šesti registry **%rdi**, **%rsi**, **%rdx**, **%rcx**, **%r8** a **%r9**, argumenty typu **float** nejprve osmi registry **%xmm0**, **%xmm1**, **%xmm2**, **%xmm3**, **%xmm4**, **%xmm5**, **%xmm6** a **%xmm7**. Další argumenty jsou předávány na zásobníku. Před voláním funkcí je zásobník zarovnán na 16 bajtů.

4.3. Použití

Nejlépe skrz **justfile** pomocí programu just.

```
just --list
```

Nebo manuálně:

Přeložení programu **program.ilang**:

```
go run cmd/compiler/main.go -i ./program.ilang -s ./program.s
gcc -no-pie -o program program.s
```

Vypsání tokenů program **program.ilang**

```
go run cmd/compiler/main.go -i ./program.ilang -tk ./program.txt
```

Vypsání AST programu **program.ilang** ve formátu dot a vytvoření obrázku

```
go run cmd/compiler/main.go -i ./program.ilang -tk ./program.dot
dot -Tpng program.dot -o program.png
```

4.4. Rozbor konkrétního programu

Následuje rozbor programu který implementuje buněčný automat rule110.

Celý zdrojový kód je dostupný v **examples/rule110.ilang**

Deklarace dvou externích funkcí:

```
extrn unit printf(string format, ...)
extrn unit scanf(string format, ...)
```

```
assembly:

.extern printf
.extern scanf
```

Deklarace funkce která vypíše stav buněk:

```
unit print_board([slice_len]int board) {
  let idx: int = 0;
  for idx < slice_len {
    printf(if !(board[idx] == 1) { " " } else { "#" });
    idx = idx + 1;
  };
  printf("\n");
}
```

Prolog funkce:

```
assembly:

print_board:
push %rbp
mov %rsp, %rbp
sub $32, %rsp # alokace lokálních proměnných
```

Přesun argumentů funkce do lokálních proměnných:

```
assembly:

mov %rdi, -24(%rbp) # odkaz na pole
mov %rsi, -16(%rbp) # délka pole
mov %rsi, -8(%rbp) # délka pole dostupná v lokální proměnné
```

Přiřazení hodnoty **0** lokální proměnné **idx**:

```
let idx: int = 0;
```

```
assembly:

mov $0, %rax
mov %rax, -32(%rbp)
```

Cyklus **for**:

```
for idx < slice_len {
  ...
};
```

```
assembly:

mov $0, %rax # výchozí návratová hodnota cyklu
.label_1:
push %rax # uložení navratové hodnoty
# binární výraz
mov -32(%rbp), %rax # levá strana - lokální proměnná
push %rax
mov -8(%rbp), %rax # pravá strana - lokální proměnná
mov %rax, %rbx
pop %rax
cmp %rbx, %rax # binární operátor - menší než
setl %al
movzbq %al, %rax
cmp $1, %rax
jne .label_2 # pokud není pravda, skok na konec cyklu
pop %rax # smazání předchozí návratové hodnoty

  ... # tělo cyklu

jmp .label_1
.label_2:
pop %rax # načtení návratové hodnoty
```

Volání externí funkce **printf** s kondicí jako argumentem:

```
printf(if !(board[idx] == 1) { " " } else { "#" });
```

assembly:

```
mov -32(%rbp), %rax # hodnota indexu
push %rax
mov -24(%rbp), %rcx # odkaz na pole
pop %rdx
mov (%rcx, %rdx, 8), %rax # indexování odkazu na pole hodnotou
push %rax
mov $1, %rax # hodnota 1
mov %rax, %rbx
pop %rax
cmp %rbx, %rax # binární operátor - rovnost
sete %al
movzbq %al, %rax
cmp $0, %rax # kondice
sete %al
movzbq %al, %rax
cmp $1, %rax
je .label_3
jmp .label_4
.label_3: # větev if
lea .const_0(%rip), %rax # odkaz na řetězec
jmp .label_5
.label_4:  # větev else
lea .const_1(%rip), %rax # odkaz na řetězec
.label_5:
push %rax
mov 0(%rsp), %rax
mov %rax, %rdi # 1. argument funkce printf
add $8, %rsp # zarovnání zásobníku
mov $0, %rax # počet variadických argumentů
call printf@PLT # volání externí funkce
```

Funkce vracející hodnotu buňky v závislosti na jejím okolí:

```
int rule110(int a, int b, int c) {
    let table: [8]int = [0, 1, 1, 1, 0, 1, 1, 0];
    let idx: int = (a << 2) || (b << 1) || c;
    table[idx]
}
```

Funkce která vypočítá nový stav buňek:

```
unit next_iter([slice_len]int board, [next_len]int next_board) {
  let a: int = 0;
  let b: int = 0;
  let c: int = 0;
  let idx: int = 0;
  for idx < slice_len {
    if idx == 0 {
      a = board[(slice_len - 1)];
    } else {
      a = board[(idx - 1)];
    };
    b = board[idx];
    if idx == (slice_len-1) {
      c = board[0];
    } else {
      c = board[(idx + 1)];
    };
    let val: int = rule110(a,b,c);
    next_board[idx] = val;
    idx = idx+1;
  };
}
```

Funkce která vypočítá a vypíše po **n** sobě jdoucích stavů buněk:

```
unit print_n_iterations([board_len]int board, [next_len]int next_board, int
iters) {
  for iters > 0 {
    let tmp: []int = board;
    next_iter(board, next_board);
    print_board(next_board);
    tmp = board;
    board = next_board;
    next_board = tmp;
    iters = iters - 1;
  }
}
```

Funkce k přečtení čísla od uživatele ze standardního vstupu:

```
int read_number_from_stdin(string prompt) {
  let number: int = 0;
  printf(prompt);
  scanf("%d", ^number);
  number
}
```

Vstupní bod programu:

```
int main() {
  let size: int = read_number_from_stdin("board size: ");
  let board: []int = make(int, size);
  let next_board: []int = make(int, size);
  board[size-1] = 1;
  print_board(board);
  print_n_iterations(board, next_board, size-1);
  release(board);
  release(next_board);
  0
}
```

Příklad výstupu pro **n** = 10:

```
board size: 10
         #
        ##
       ###
      ## #
     #####
    ##   #
   ###  ##
  ## # ###
 ####### #
##     ###
```